Programa Certified AI-LLM Solution Architect

Proyecto Final AI-LLM Solution Architect

Definiciones

Sesión 3 y Sesión 4

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Leaning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data at IEBSchool – Barcelona, Spain
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialista en MLOps de la Universidad de Duke
- Estudiante de la especialización Deep Learning for Healthcare de la Universidad de Illinois



andres.rojas@triskelss.com
@arojaspa
https://www.linkedin.com/in/arojaspa/
+573005906373

CAPÍTULO 2

02

SESIÓN 3

BSG Institute

Selección de Tecnologías y Diseño Arquitectónico

Las decisiones tecnológicas determinan los límites del sistema — no al revés.

Stack LLM | Cloud Platform | Diagramas C4 | ADRs | Vector Store

OBJETIVOS DE LA SESIÓN

¿Qué dominarán al finalizar la Sesión 3?

Evaluar

Comparar plataformas LLM y cloud usando criterios cuantificables: TCO, latencia, compliance y developer experience.

Diseñar

Construir diagramas de arquitectura C4 (Contexto + Contenedor) con todos los componentes, relaciones y tecnologías del sistema.

Documentar

Redactar ADR-001 y ADR-002 (LLM base y vector store) con alternativas, trade-offs y condiciones de revisión explícitas.

Especificar

Definir el pipeline RAG completo: chunking, embeddings, top-k, umbral de similitud y estrategias avanzadas de recuperación.

Marco de Decisión Tecnológica — Seis Ejes

Toda decisión de stack debe evaluarse en 6 dimensiones antes de comprometerse arquitectónicamente:

Rendimiento

Latencia p50/p95, TTFT, throughput RPS

Costo Total

TCO 12 meses, costo por token, egress

Ecosistema

Integraciones, SDKs, comunidad, plugins

Madurez

Uptime SLA, soporte enterprise, roadmap

Seguridad

Compliance (SOC2, GDPR), data residency

Dev Experience

Documentación, DX, velocidad de onboarding

S3 · LLM BASE — COMPARATIVA

Selección del Modelo LLM Base — Tabla Comparativa

Esta tabla es el insumo directo para el ADR-001. Cada star (★) representa ~20 puntos en la dimensión evaluada.

Modelo / Plataforma	Rendimiento	Costo TCO	Ecosistema	Madurez	Seguridad	Dev XP
OpenAI GPT-4o	★★★★★	★★★☆☆	★★★★★	★★★★★	★★★★☆	★★★★★
Anthropic Claude 3.5	★★★★★	★★★☆☆	★★★★☆	★★★★★	★★★★★	★★★★☆
Llama 3 (Self-hosted)	★★★★☆	★★★★★	★★★☆☆	★★★☆☆	★★★★★	★★★☆☆
Gemini 1.5 Pro	★★★★☆	★★★★☆	★★★★☆	★★★★☆	★★★★☆	★★★★☆

⚡ *Esta comparativa es el punto de partida. El ADR-001 documentará formalmente la decisión con trade-offs explícitos y condiciones de revisión.*

Vector Store y Frameworks de Orquestación LLM

Vector Stores — Criterios Clave

Pinecone

SaaS managed · Bajo ops overhead · Excelente escala · USD $70+/mes

Weaviate

Open source + cloud · GraphQL/REST · Multi-modal · Auto-schema

Qdrant

Rust-based · Filtros payloads · Auto-backup · Self/Cloud

pgvector

PostgreSQL extension · Menor latencia para <5M vectores · Sin costos extra

Frameworks de Orquestación LLM

MÁS MADURO

LangChain

Ecosistema más rico. Ideal para RAG, chains, agentes y memoria. Gran comunidad OSS.

RAG-FIRST

LlamaIndex

Especializado en ingestión y recuperación. Mejor abstracción de índices y conectores de datos.

AZURE/.NET

Semantic Kernel

Microsoft. Integración nativa con Azure OpenAI. Ideal para entornos .NET empresariales.

S3 - CONCEPTO CLAVE — C4

Diagrama C4 — Modelo de Visualización Arquitectónica

Creado por Simon Brown — 4 niveles de zoom: Contexto, Contenedores, Componentes y Código

NIVEL 1
Contexto

Vista más amplia. Sistema como caja negra, actores y sistemas externos.

NIVEL 2
Contenedores

Piezas desplegables: API, orquestador LLM, vector store, BD.

NIVEL 3
Componentes

Módulos internos de un contenedor: RAG, memoria, guardrails.

NIVEL 4
Código

Diagramas UML de clases. Rara vez se usa (se desactualiza rápido).

💡 **Idea Central**

No existe un solo diagrama para todas las audiencias. Necesitas diferentes niveles de zoom: Contexto para el CEO, Contenedores para el ingeniero nuevo, Componentes para el equipo técnico.

📋 **Entregable del Programa**

Los estudiantes deben entregar Nivel 1 (Contexto) y Nivel 2 (Contenedores) — los más útiles en la práctica.

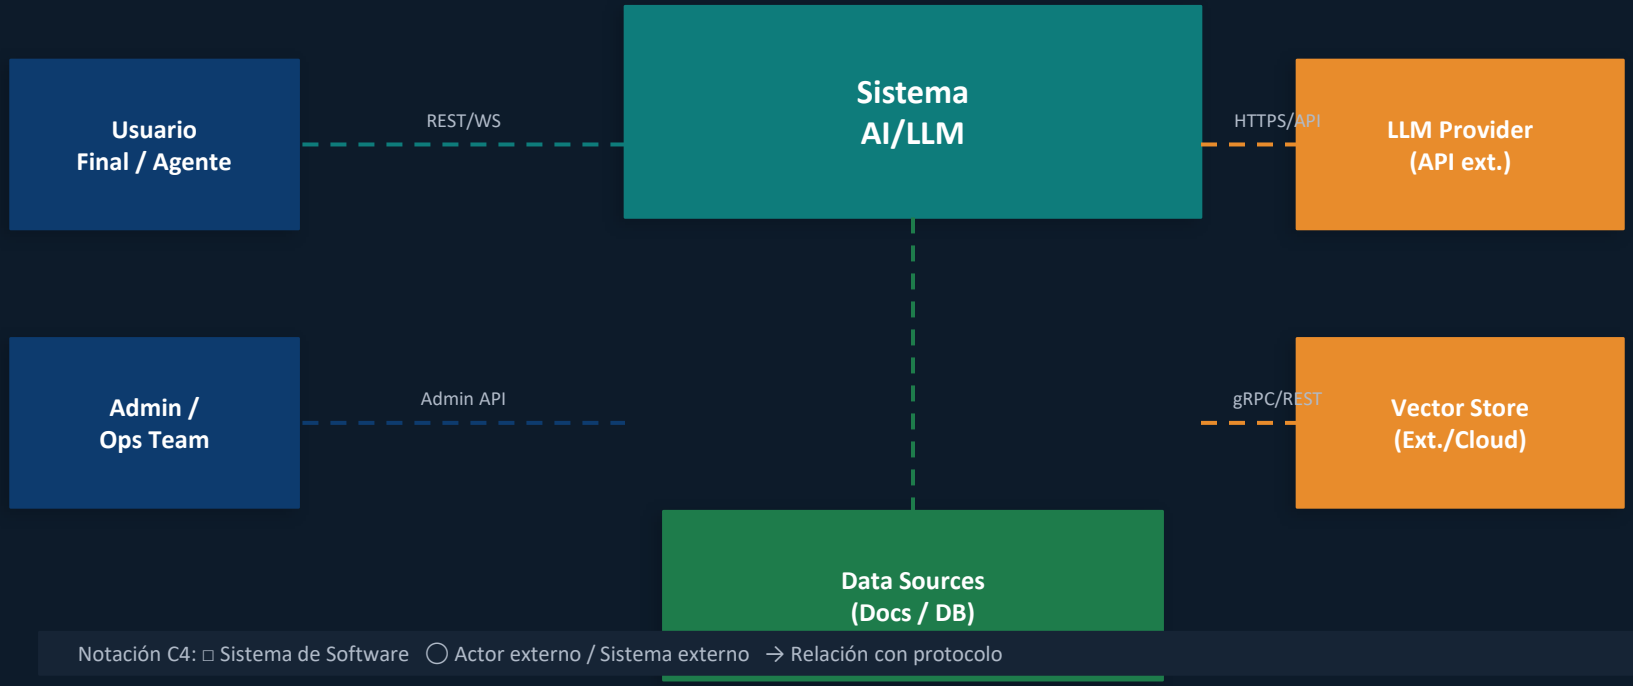
🎯 **Audiencia por Nivel**

N1: CEO / Cliente · N2: Ingeniero nuevo · N3: Equipo técnico · N4: Rara vez

Modelo creado por Simon Brown · c4model.com

Diagrama C4 — Nivel 1: Contexto del Sistema

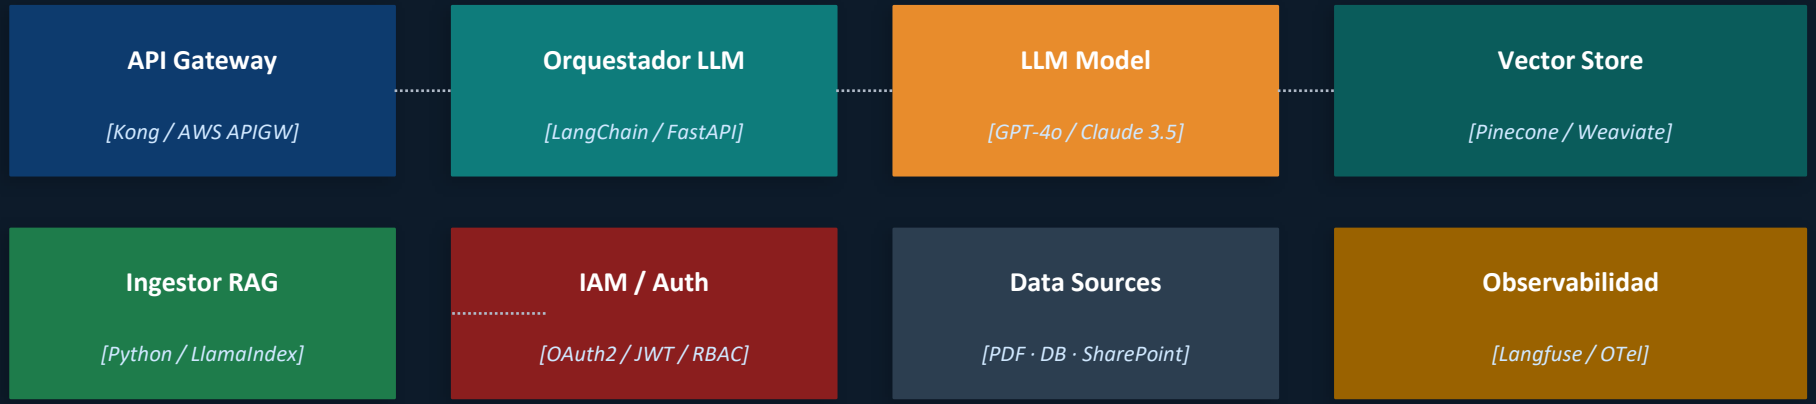
El diagrama de contexto muestra QUÉ hace el sistema y con QUIÉN interactúa — sin entrar en detalles internos.



Notación C4: □ Sistema de Software ◯ Actor externo / Sistema externo → Relación con protocolo

Diagrama C4 — Nivel 2: Contenedores del Sistema

El diagrama de contenedores descompone el sistema en sus componentes desplegables y las tecnologías que los implementan.



Todos los contenedores se despliegan en cloud (AWS / Azure / GCP). Cada uno tiene su propio ciclo de vida, escala independiente y SLA individual.

API Gateway: Rate limiting, auth pre-check, routing · Orquestador: Pipeline RAG, memory, tool calls · IAM: Zero-trust, RBAC, audit logging · Observabilidad: Traces LLM, métricas RAGAS, costos

S3 - CONCEPTO CLAVE — ADR

ADR — Architecture Decision Record

Documento corto que registra una decisión arquitectónica importante, su contexto y sus consecuencias.

📄 Estructura de un ADR

1. **Título y estado**
   Propuesto / Aceptado / Deprecado
2. **Contexto**
   ¿Qué problema forzó esta decisión?
3. **Decisión**
   Qué se eligió, en una oración clara
4. **Alternativas**
   Opciones evaluadas y descartadas
5. **Trade-offs**
   Qué se gana y qué se sacrifica
6. **Consecuencias**
   Impacto en el resto de la arquitectura
7. **Revisión**
   Cuándo revisitar esta decisión

❓ ¿Por qué son necesarios?

En todo proyecto se toman decenas de decisiones:
"¿PostgreSQL o MongoDB?" "¿AWS o Azure?"
Sin documentarlas, viven solo en la cabeza de quien las tomó. Cuando esa persona se va, nadie sabe por qué el sistema está construido así.

📋 Entregables del Programa

ADR-001 — Selección del modelo LLM
ADR-002 — Selección del vector store

Son los dos pilares tecnológicos del sistema. Elegirlos sin documentar el razonamiento es un error común que después cuesta caro.

ADR — Anatomía de una Decisión Arquitectónica Bien Documentada

ADR-001 | Alta prioridad | Estado: Aceptado

Título: Selección del Modelo LLM Base para el Sistema

Contexto: El sistema procesa 2K consultas/día sobre docs corporativos. Requiere p95 < 3s, soporte multiidioma y compliance SOC2.

Decisión: Se adopta GPT-4o via Azure OpenAI como modelo LLM base para v1.0.

Alternativas: A1: GPT-4o (Azure OpenAI) · A2: Claude 3.5 · A3: Llama 3 self-hosted

Trade-offs: A1: Mayor costo token vs máxima DX y compliance · A3: Sin costo pero alta carga ops

Consecuencias: + Soporte nativo Azure AD + SLA 99.9% - Vendor lock-in con Microsoft/OpenAI

Revisión: Reevaluar si costo supera USD 800/mes o si Llama 4 alcanza paridad en benchmarks.

Criterios para ADR de Máxima Puntuación

- ✓ ≥ 3 alternativas comparadas con tabla cuantitativa
- ✓ Trade-offs positivos Y negativos documentados
- ✓ Condición de revisión concreta y medible
- ✓ Criterios de selección ponderados numéricamente
- ✓ Contexto técnico específico (no genérico)
- ✓ Consecuencias de la decisión en la arquitectura
- ✗ Anti-patrón: ADR sin alternativas ni trade-offs

Diseño del Pipeline RAG — Parámetros Clave

Etapas del Pipeline RAG

1. **Ingestión**
   Fuentes: PDF, Word, DB · Frecuencia: batch / incremental
2. **Chunking**
   Tipo: recursive / semantic · Tamaño: 512-1024 tokens · Overlap: 10-15%
3. **Embedding**
   Modelo: text-embedding-3-large · Dims: 1536 · Costo por 1M tokens
4. **Indexado**
   Vector store: Pinecone/Qdrant · Metadata filterable · Batch upsert
5. **Recuperación**
   Top-k: 5 · Similarity threshold: ≥ 0.78 · MMR o re-ranking opcional
6. **Generación**
   Contexto + system prompt + historial → LLM → respuesta fundamentada

System Prompt Base — Estructura

ROL

Eres un asistente experto en políticas corporativas de [Empresa]...

RESTRICCIONES

NO inventes información. Si no está en el contexto, responde: 'No tengo información sobre este tema'.

FORMATO

Responde en español, máximo 3 párrafos, con fuente [Documento – Pág. X].

OUT-OF-SCOPE

Si la consulta no es sobre [dominio], redirige amablemente al canal correcto.

TÉCNICA AVZ.

Aplica re-ranking semántico sobre los k=5 fragmentos recuperados antes de generar.

Resumen Sesión 3

¿Qué construiste hoy?



Marco de selección tecnológica (6 ejes)



Diagrama C4 Contexto + Contenedor



ADR-001 y ADR-002 documentados



Pipeline RAG + System Prompt base

PRÓXIMO: Sesión 4 — Plan de Integración

Diseño de APIs · Estrategias de Seguridad · Modelo de Amenazas · Topología de Despliegue

CAPÍTULO 2

02

SESIÓN 4

BSG Institute

Plan de Integración: APIs, Seguridad y Despliegue

Una arquitectura sin plan de integración es solo un diagrama bonito — no un sistema.

APIs OpenAPI | Seguridad Zero-Trust | Modelo Amenazas | Topología Cloud | Entregable E2

Especificación OpenAPI — Anatomía de un Endpoint de Producción

Endpoints Principales del Sistema

POST `/v1/query`
Consulta principal al sistema RAG

GET `/v1/health`
Health check del sistema completo

POST `/v1/documents`
Ingestión y actualización de docs

GET `/v1/traces/{id}`
Observabilidad de una llamada LLM

POST `/v1/feedback`
Registro de feedback del usuario

GET `/v1/metrics`
Métricas de calidad RAGAS + costos

POST /v1/query — Request & Response Schema

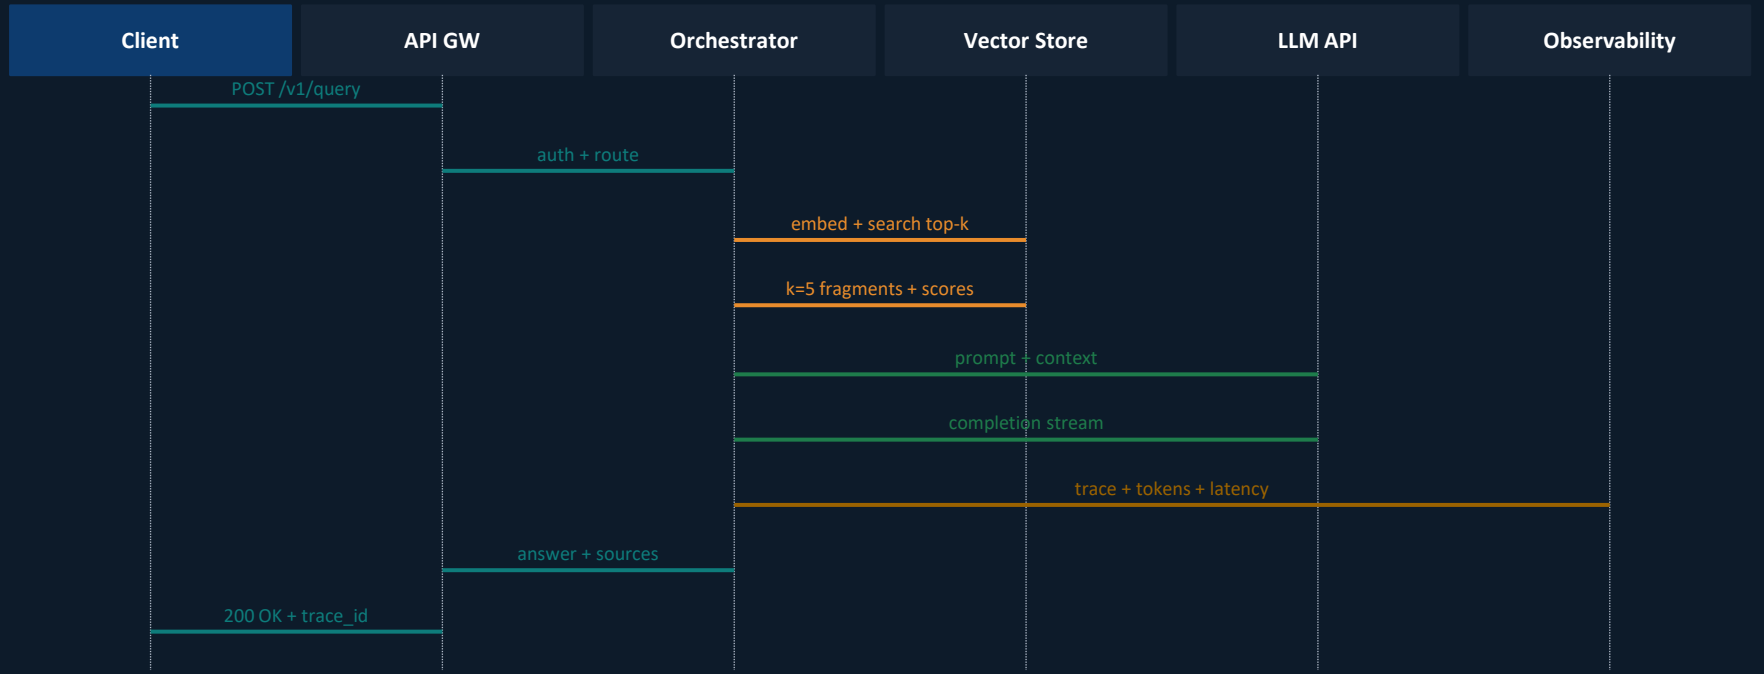
```
Request Body:
{
  "query": "string (max 2048 tokens)",
  "session_id": "uuid (historial)",
  "filters": { "doc_type": "policy|manual" },
  "stream": false
}
```

```
Response 200:
{
  "answer": "string",
  "sources": [{ "doc_id", "page", "score" }],
  "tokens_used": 1248,
  "latency_ms": 1420,
  "trace_id": "uuid"
}
Errors: 400, 401, 422, 429, 503
```

S4 · FLUJO DE DATOS

Ciclo Completo Request → RAG → LLM → Response

Diagrama de secuencia: cada flecha documenta el protocolo, payload y timeout/error que aplica.



S4 · SEGURIDAD Y CUMPLIMIENTO

Estrategia de Seguridad — Zero-Trust para Sistemas AI/LLM



Autenticación / IAM

OAuth 2.0 + PKCE
JWT con expiración corta (15 min)
RBAC por rol y tenant
MFA para accesos privilegiados



Defensa contra Prompts

Guardrails de entrada: regex + LLM classifier
Sanitización de inputs
Bloqueo de PII en contexto RAG
Rate limiting por usuario/hora



Protección de Datos

Cifrado en tránsito: TLS 1.3
Cifrado en reposo: AES-256
Data residency por jurisdicción
Retención configurable por tenant



Observabilidad y Audit

Audit log inmutable por consulta
Traza distribuida (OpenTelemetry)
Alertas SIEM por anomalías
DSAR support (GDPR Art. 15-17)



Topología de Red

VPC privada + Private Link a APIs
WAF en API Gateway
Egress filtering a LLM providers
Network policies en K8s (Calico)



Cumplimiento Normativo

GDPR / CCPA: consentimiento y DSARs
SOC2 Type II (proveedor LLM)
Regulación financiera local
Modelo de amenazas STRIDE inicial

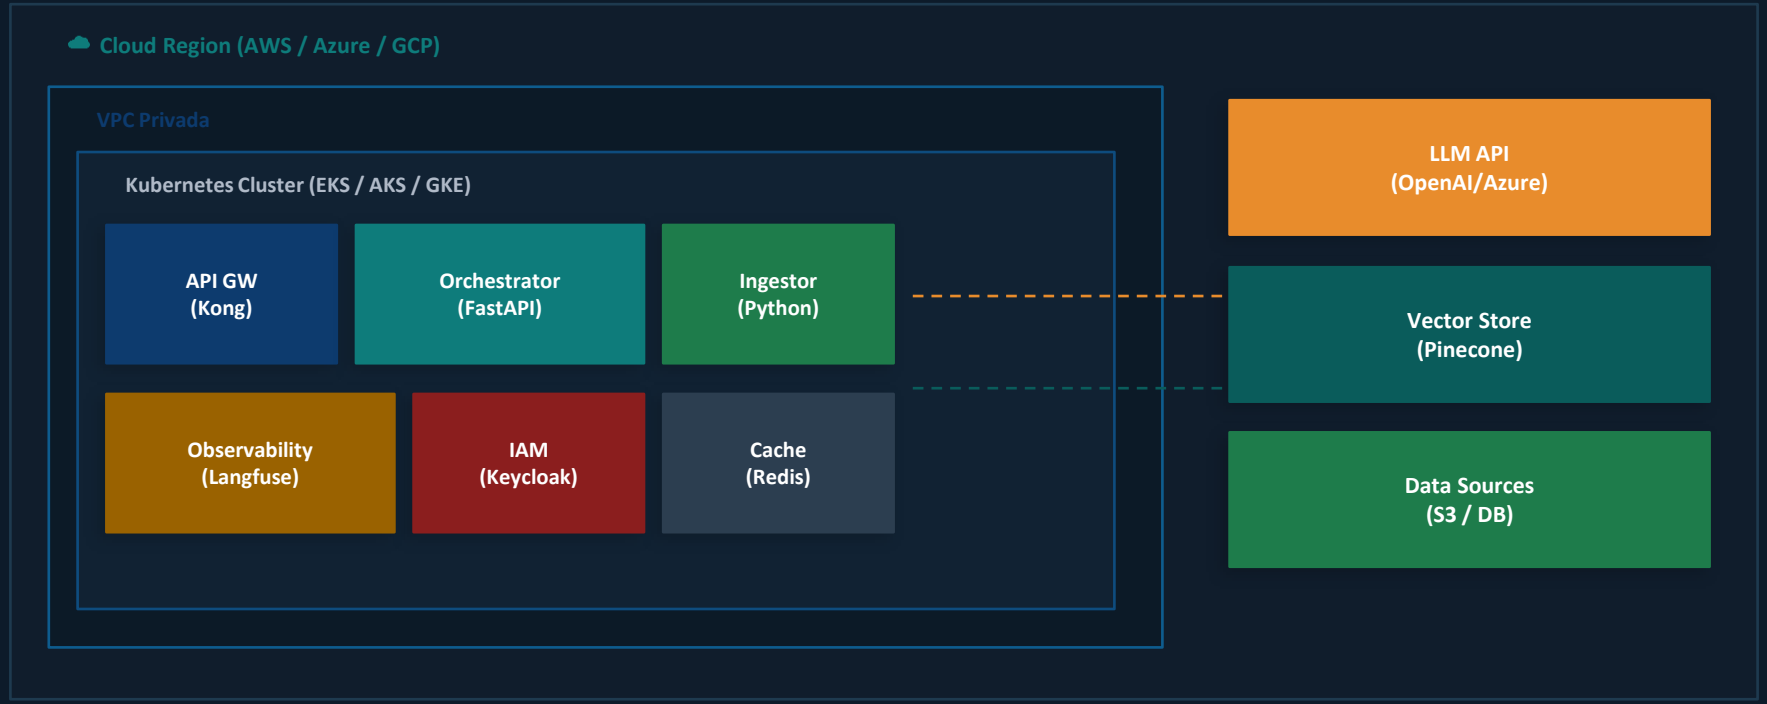
S4 · MODELO DE AMENAZAS

Modelo de Amenazas Inicial — Framework STRIDE para AI/LLM

STRIDE clasifica amenazas en 6 categorías. En sistemas AI/LLM, Tampering (prompt injection) y Information Disclosure (data leakage) son las de mayor probabilidad.

	Amenaza	Descripción	Control	Riesgo
S	**Spoofing**	Suplantación de identidad de usuarios o sistemas	MFA, JWT firmado, mTLS entre servicios	ALTO
T	**Tampering**	Prompt injection, manipulación de embeddings en vector store	Guardrails, validación de inputs, checksums de índices	CRÍTICO
R	**Repudiation**	Negación de consultas realizadas o acciones del sistema	Audit log inmutable, firma digital de trazas	MEDIO
I	**Information Disclosure**	Filtración de datos confidenciales en respuestas LLM	PII scrubbing, DLP en outputs, namespace isolation	CRÍTICO
D	**Denial of Service**	Saturación de tokens/hora, costos cloud desbordados	Rate limiting, presupuesto por tenant, circuit breaker	ALTO
E	**Elevation of Privilege**	Prompt que engaña al LLM para ejecutar acciones no autorizadas	RBAC estricto, tool validation, human-in-the-loop para acciones críticas	ALTO

Topología de Comunicación y Despliegue Cloud



Private Link / VPC Endpoint — tráfico nunca sale a internet público

ENTREGABLES CAPÍTULO 2

Entregable 2 — Diseño de Arquitectura (Cap. 2)

Peso como hito: 18 puntos (progreso) · Sesiones S3–S4 · Entrega: Fin de S4

✓ OBL	2.1	Secciones 3 y 4 de la Plantilla Oficial completadas
✓ OBL	2.2	Diagrama de arquitectura C4 (Contexto + Contenedor) — PNG/SVG alta res.
✓ OBL	2.3	Diagrama de flujo de datos / secuencia del ciclo request→response
✓ OBL	2.4	ADR-001: Selección del modelo LLM base
✓ OBL	2.5	ADR-002: Selección del vector store
✓ OBL	2.6	Especificación OpenAPI inicial (endpoints principales con schemas)
✓ OBL	2.7	System prompt base documentado con rol, restricciones y formato
✓ OBL	2.8	Parámetros RAG especificados y justificados (chunk size, top-k, threshold)
✓ OBL	2.9	Modelo de amenazas inicial (sección 5 de la plantilla)
⚠ Rec.	2.10	ADR-003 adicional (cualquier decisión técnica relevante)
⚠ Rec.	2.11	Prototipo mínimo con endpoint /health operativo

Todos los entregables se suben al repositorio Git del proyecto. Entregables tardíos aplican penalización del 20%.

DIMENSIÓN 2 — EVALUACIÓN

Dimensión 2 — Criterios de Evaluación (20 pts)

Propósito: Evalúa la capacidad de diseñar una arquitectura AI/LLM técnicamente sólida, justificada con trade-offs explícitos y comunicable mediante diagramas estándar de la industria.

2.1 Diagrama de Arquitectura — 6 pts

MAX: Notación C4 completa. Todos los componentes: actores, API GW, orquestador, LLM, vector store, IAM, observabilidad. Relaciones con protocolo, dirección y tecnología concreta.

MED: Muestra componentes principales con relaciones claras. Puede faltar algún componente secundario.

LOW: Diagrama incompleto o genérico sin adaptación al caso de uso.

2.2 Architecture Decision Records (ADRs) — 7 pts

MAX: ≥ 3 ADRs. Cada uno con contexto técnico, decisión, tabla de alternativas con criterios cuantificables, consecuencias positivas/negativas y condiciones de revisión.

MED: ≥ 2 ADRs bien documentados. Alternativas identificadas aunque la comparación podría ser más rigurosa.

LOW: ADRs superficiales o sin estructura / justificación técnica verificable.

2.3 Pipeline RAG y Prompts — 4 pts

MAX: Pipeline completamente especificado: chunking justificado, embedding model, top-k, threshold. System prompt con rol, restricciones y manejo out-of-scope. Al menos una técnica avanzada.

MED: Pipeline con parámetros principales. System prompt presente y guía el comportamiento del modelo.

LOW: Pipeline presente con parámetros por defecto sin justificación. System prompt genérico.

2.4 APIs y Flujo de Integración — 3 pts

MAX: Especificación OpenAPI completa con schemas request/response, ejemplos reales y errores documentados. Diagrama de secuencia con ciclo completo incluyendo timeouts.

MED: OpenAPI cubre endpoints principales con schemas básicos. Puede faltar manejo de errores o casos borde.

LOW: Especificación parcial o inconsistente con la implementación real.

ACTIVIDAD PRÁCTICA EN CLASE

Taller Integrador — Sesión 4: 45 minutos

Usando el mismo caso financiero de S1 (empresa 500 emp., 2K consultas/día), diseñen los componentes de integración:

10 min

1. Especificación OpenAPI

Definan el endpoint POST /v1/query completo: request schema con filtros, response con fuentes y trace_id, manejo de errores 422 (tokens excedidos), 429 (rate limit) y 503 (LLM timeout).

15 min

2. ADR-002: Vector Store

Redacten el ADR-002 completo. Comparen Pinecone vs Qdrant vs pgvector para el caso. Incluyan tabla con: costo estimado, latencia esperada, ops overhead y compliance. Justifiquen la elección.

10 min

3. Top 3 Amenazas STRIDE

Identifiquen las 3 amenazas más críticas para este sistema financiero (clientes reales, datos sensibles). Para cada una: descripción del vector de ataque, control técnico concreto y quién es el owner.

10 min

4. Presentar y Debatir

Cada equipo presenta su ADR-002 y trade-off más difícil. El instructor facilita: ¿Qué pasa si Pinecone falla? ¿Circuit breaker o fallback a búsqueda keyword? ¿Data residency limita opciones?

¿Qué aprendiste en el Capítulo 2?

Seleccionar tecnologías con criterios cuantificables

Diseñar diagramas C4 Contexto + Contenedor

Documentar ADRs con trade-offs explícitos

Modelo de amenazas STRIDE para AI/LLM

PRÓXIMO: Capítulo 3 — Implementación y Pruebas

Prototipo funcional · Pipeline RAG en código · Tests de calidad RAGAS · Evaluación end-to-end del sistema

Recordatorio — Entregable 2

Diagrama C4 + ADR-001 + ADR-002 + OpenAPI spec + System Prompt + Parámetros RAG + Modelo de Amenazas → repositorio Git antes del inicio de S5